

Планирование в MiniGrid с использованием world model и VLM-оценки

Роман Хакимов

6 июля 2026 г.

1. Введение

В работе рассматривается задача навигации в среде MiniGrid. Агент должен достичь целевой клетки, используя три действия: поворот налево, поворот направо и движение вперёд.

Цель эксперимента - сравнить три подхода к управлению агентом: случайное блуждание, планирование с использованием обученной world model и планирование, в котором imagined states дополнительно оцениваются с помощью vision-language model.

Во всех model-based подходах агент на каждом шаге генерирует набор последовательностей действий, предсказывает их последствия с помощью world model, выбирает лучшую последовательность по заданной функции оценки и выполняет только первое действие.

2. Постановка эксперимента

Среда представляет собой задачу навигации в MiniGrid. Состояние задаётся координатами агента, его направлением, картой стен и картой цели. Доступные действия: left, right, forward.

Во всех model-based методах использовалась одна и та же схема MPC: на каждом шаге генерировались случайные последовательности действий, world model предсказывала будущие состояния, после чего выбиралась последовательность с максимальной оценкой.

Таблица 1: Основные параметры эксперимента

Параметр	Значение
Среда	MiniGrid
Действия	left, right, forward
World model	state-based RSSM
Планировщик	random shooting MPC
VLM	CLIP ViT-B/16
Метрики	success rate, return, steps




Рис. 1: Пример карты

3. Методы

3.1. Random policy

Случайная политика выбирает одно из трёх действий равновероятно на каждом шаге. Она используется как нижняя граница качества и не использует ни карту, ни world model, ни VLM.

3.2. World-model planning без VLM

В этом методе агент использует обученную world model для предсказания будущих состояний. Каждая последовательность действий оценивается по raw Manhattan progress к цели, вычисленному по координатам, предсказанным моделью.

Метод не использует BFS, точную динамику MiniGrid или oracle planner. Для уменьшения застревания добавлен простой anti-stuck штраф.

3.3. World-model planning с VLM-оценкой

В VLM-варианте предсказанные состояния рендерятся стандартным MiniGrid renderer'ом и оцениваются с помощью CLIP. Чтобы убрать зависимость от направления агента, CLIP-score усредняется по направлениям и используется как позиционный score по клеткам карты.

В итоговом варианте CLIP-score комбинируется с Manhattan progress и anti-stuck штрафом. Этот метод обозначается как **RSSM + CLIP-xy-progress MPC**.

3.4. Датасет для обучения world model

Датасет собирался из траекторий агента в MiniGrid. На каждом шаге сохранялись структурированное состояние среды, действие агента, reward, флаг завершения и следующее состояние:

$$(s_t, a_t, r_t, done_t, s_{t+1}).$$

Состояние включало координаты агента, его направление, карту стен и карту цели. Траектории генерировались случайной политикой по действиям `left`, `right`, `forward`. На этих данных `world model` обучалась предсказывать динамику среды для последующего MPC-планирования.

4. Количественные результаты

Для сравнения использовались эпизоды с фиксированными `seed`’ами. Для всех трёх политик было проведено по 100 эпизодов. Полные `per-episode` результаты сохранены в ноутбук.

Таблица 2: Сравнение политик

Метод	Эпизодов	Candidates / horizon	Success rate	Mean return	Mean steps	Timeout rate
Random policy	100	—	0.12	0.079	300.74	0.87
RSSM distance MPC	100	2048 / 15	0.39	0.336	217.09	0.61
RSSM CLIP-xy-progress MPC	100	1024 / 15	0.46	0.340	218.13	0.54

Случайная политика редко достигает цели и чаще всего завершается `timeout`’ом. Планирование с `world model` без VLM заметно улучшает результат относительно `random baseline`, что показывает полезность `learned dynamics` для `short-horizon planning`.

Лучший VLM-вариант показал наибольший `success rate` среди рассмотренных методов: 0.46 против 0.39 у `distance-based MPC`. При этом средний `return` и среднее число шагов остались близкими к `baseline` без VLM. Это говорит о том, что CLIP-оценка может давать полезный дополнительный сигнал, но основной вклад в стабильное поведение всё ещё вносит геометрический `progress term` и `anti-stuck` логика.

5. Визуализации

В репозитории приложены GIF-файлы внутри ноутбука с примерами эпизодов для разных политик.

6. Обсуждение

Сначала была попытка обучать `world model` напрямую по изображениям среды. Этот вариант оказался слишком нестабильным: модели было сложно одновременно восстанавливать карту, положение агента и динамику. Поэтому далее использовалось структурированное состояние: координаты агента, направление, карта стен и карта цели.

Главный `failure mode` в экспериментах — застревание агента около стен и углов. В таких ситуациях агент часто упирался в стену, оставался в той же клетке и начинал поворачиваться на месте. Большинство `timeout`’ов связано именно с таким поведением.

Для борьбы с этим добавлялись `anti-stuck` штрафы: за отсутствие движения, за повторное нахождение в той же клетке и за `rollouts`, где агент не выходит из текущей позиции в первые шаги. Это улучшило поведение, но полностью проблему не устранило.

В VLM-варианте дополнительной сложностью был шумный CLIP-score: он не всегда давал высокий `score` целевой клетке и мог зависеть от направления агента. Поэтому в итоговом методе CLIP использовался только как дополнительный позиционный сигнал вместе с `raw progress` и `anti-stuck` логикой.




Рис. 2: CLIP-score в этой карте плохо совпадает с реальной целью навигации

7. Дальнейшая работа

В дальнейшем стоит проверить подход на более сложных картах MiniGrid, например с ключами, дверями и несколькими объектами. Текущая задача в основном проверяет геометрическую навигацию, тогда как такие среды лучше показывают пользу VLM.

Также стоит сравнить разные VLM-модели. Используемый CLIP ViT-B/16 не обязательно оптимален для небольших gridworld-рендеров, поэтому более сильные или дообученные модели могут дать более стабильный score.

Ещё одно направление - улучшение функции оценки rollout'ов. Scorer может лучше учитывать столкновения со стенами, повторяющиеся состояния, прогресс по всей траектории и застревание в углах.

Кроме того, можно обучить небольшой reward model поверх CLIP embeddings на автоматически размеченных MiniGrid-состояниях. Наконец, random shooting можно заменить на CEM, чтобы эффективнее искать хорошие последовательности действий.